

Proyecto Análisis Exploratorio de Datos

María de los Ángeles Díaz Castro, Irene Barba La Orden, Ana Blasco Vega

* Correspondence:

1. Introducción.

El tráfico de vehículos va más allá de los números, muestra cómo Valencia se mueve, organiza y enfrenta cada día sus desafíos de desplazamiento. Este proyecto se centra en analizar la intensidad del tráfico en las carreteras de la Comunidad Valenciana durante el primer semestre de 2025, a partir de datos públicos proporcionados por la Generalidad Valenciana. A través de un análisis exploratorio de 15.235 observaciones, se busca detectar las posibles anomalías en el tráfico y explorar el comportamiento de la movilidad en Valencia.

2. Importación de los datos.

Para importar los datos, primero se descarga el fichero y se verifica que los datos estén en el directorio adecuado. Es importante especificar el encoding (en nuestro caso es UTF-8), ya que, de lo contrario, algunos caracteres pueden no reconocerse correctamente. De esta forma, haciendo uso de la función de importación en R con los parámetros adecuados, obtenemos el dataset.

Las variables de nuestro dataset son las siguientes:

- TRAM** (*numérico*): Código del tramo al que se le asocia el tráfico.
Primer y segundo dígito: código CV- de la carretera; tres últimos dígitos: número de tramo.
- DIA** (*carácter*): Fecha de los datos.
- INTA** (*numérico*): Total de vehículos que transitan en el sentido ascendente de la kilometración de la carretera.
- INTAP** (*numérico*): Total de vehículos pesados que transitan en el sentido ascendente de la kilometración de la carretera.
- INTD** (*numérico*): Total de vehículos que transitan en el sentido descendente de la kilometración de la carretera.
- INTDP** (*numérico*): Total de vehículos pesados que transitan en el sentido descendente de la kilometración de la carretera.
- INTT** (*numérico*): Total de vehículos que pasan por el tramo analizado (este dato será la suma de los dos sentidos anteriores).
- INTTP** (*numérico*): Total de vehículos pesados que pasan por el tramo analizado (este dato será la suma de los dos sentidos anteriores).
- TIPUSV** (*carácter*): Tipo de vía (Autovía, Convencional o Desdoblada).
- TIPUSE** (*carácter*): Procedimiento de captura de tráfico (Espiras, Gomas Neumáticas, Cámaras o Radar).

Citation: . Proyecto Análisis Exploratorio de Datos. *Journal Not Specified* **2024**, *1*, 0. <https://doi.org/>

Received:

Revised:

Accepted:

Published:

Copyright: © 2025 by the authors. Submitted to *Journal Not Specified* for possible open access publication under the terms and conditions of the Creative Commons Attribution (CC BY) license (<https://creativecommons.org/licenses/by/4.0/>).

11. **PKE** (*numérico*): Posición exacta, en metros, donde se ha captado el tráfico, tomando como referencia la placa de kilometraje anterior en sentido ascendente.
12. **PKECOOR** (*carácter*): Coordenadas geodésicas en latitud y longitud del punto donde se mide el tráfico.
13. **PKINI** (*numérico*): Posición inicial del tramo al que se asocia el tráfico, en metros, tomando como referencia la placa kilométrica anterior en sentido ascendente (tráfico invariante en todo el tramo).
14. **REFINI** (*carácter*): Ubicación del inicio del tramo al que se asocia el tráfico.
15. **PKINICOOR** (*carácter*): Coordenadas geodésicas en latitud y longitud del punto inicial del tramo al que se asocia el tráfico (tráfico invariante en todo el tramo).
16. **PKFI** (*numérico*): Posición final del tramo al que se asocia el tráfico, en metros, tomando como referencia la placa kilométrica anterior en sentido ascendente (tráfico invariante en todo el tramo).
17. **REFFI** (*carácter*): Ubicación del final del tramo al que se asocia el tráfico.
18. **PKFICOOR** (*carácter*): Coordenadas geodésicas en latitud y longitud del punto final del tramo al que se asocia el tráfico (tráfico invariante en todo el tramo).

Si le echamos un vistazo a las variables, podemos ver que la variable *DIA* es de tipo *character*, por lo que es necesario convertirla a formato de fecha. Para ello, usamos la función `as.Date()`. Por otro lado, es importante preguntarse con cuántos valores faltantes estamos trabajando, para ello usamos `is.na()` y sumamos los valores faltantes, obteniendo:

```
## [1] 0
```

Como no tenemos valores faltantes, no será necesario llevar a cabo ningún proceso de imputación o similar.

3. Conversión de los datos a estructura Tidy.

La estructura tidy se caracteriza por tener cada variable en una columna, cada observación en una fila y nombres de columnas que sean representativos. Para obtener un conjunto tidy, vamos a realizar diversas transformaciones en nuestros datos para facilitar su análisis.

Comenzamos reorganizando las variables relacionadas con la intensidad del tráfico (*INTA*, *INTAP*, *INTD*, *INTDP*, *INTT* y *INTTP*). Estas columnas almacenan información sobre el sentido del tráfico (ascendente, descendente o total) y el tipo de vehículo (pesado o total), por lo que están estrechamente relacionadas entre sí.

Para convertir el conjunto de datos en tidy, optamos por transformar el formato ancho en uno largo, de modo que cada fila represente una combinación única de tramo, sentido y tipo de vehículo. Para ello aplicamos la función `pivot_longer()`, que nos permite condensar varias columnas en dos nuevas variables: *Sentido*, que indica la dirección del tráfico, y *Tipo_Vehiculo*, que diferencia entre vehículos pesados (P) y el total (T).

De forma análoga, se aplicaron transformaciones similares a otras variables, como *TRAM*, las ubicaciones (*REFINI*, *REFFI*) y los puntos kilométricos (*PKINI*, *PKFI*, *PKE*). En el caso de las variables de coordenadas (*PKECOOR*, *PKINICOOR*, *PKFICOOR*), que distinguen entre la posición inicial, final y exacta, como cada coordenada incluye la latitud y la longitud separadas por un punto y coma, usamos la función `separate()` para dividir cada columna en longitud y latitud. El separador decimal del conjunto eran las comas, por lo que R detectaba las columnas como tipo carácter. Lo solucionamos usando la función `sub()` para reemplazar las comas por puntos, lo que nos permite convertir correctamente los valores a tipo numérico. Después de convertirlas a tipo numérico, acabamos con las variables

Latitud_Inicio, Longitud_Inicio, Latitud_Final, Longitud_Final, Latitud_Exacta y Longitud_Exacta.

Solo falta asegurarnos de que los nombres de las columnas sean representativos; para ello, utilizamos la función `rename()` y reemplazamos algunos valores abreviados por descripciones completas mediante la función `ifelse()`. Por ejemplo, en las variables relacionadas con ubicación, los códigos *INI*, *E* y *FI* se sustituyeron por *Inicial*, *Exacta* y *Final*; en *Sentido*, los valores *A* y *D* pasaron a *Ascendente* y *Descendente*; y en *Tipo_Vehiculo*, *T* y *P* se cambiaron por *Todos* y *Pesados*.


4. Análisis univariante y gráficos exploratorios

En esta sección exploraremos los datos mediante un análisis univariante de las variables numéricas y el uso de gráficos. Las variables numéricas de las que disponemos son *Flujo_Vehiculos*, *Valor_Punto_Quilometrico*, y las coordenadas geográficas de los puntos en los que se mide el flujo, así como las de los puntos que se han designado como inicio y fin del tramo en el que se asume que el tráfico es invariante.


##	Mínimo	Máximo	Rango	IQR	Q0.25	Mediana
## Latitud_Exacta	37.89	40.71	2.82	0.81	38.87	39.54
## Longitud_Exacta	-1.20	0.43	1.63	0.29	-0.64	-0.50
## Latitud_Inicio	37.89	40.65	2.76	0.81	38.86	39.53
## Longitud_Inicio	-1.21	0.43	1.65	0.28	-0.62	-0.49
## Latitud_Final	37.13	40.73	3.60	0.80	38.89	39.54
## Longitud_Final	-1.25	0.44	1.69	0.29	-0.64	-0.50
## Flujo_Vehiculos	0.00	999.00	999.00	175.84	4.16	16.63
## Valor_Punto_Quilometrico	0.00	95090.00	95090.00	22910.00	3500.00	10200.00
##	Media	Q0.75	Desviación_típica			
## Latitud_Exacta	39.32	39.68		0.65		
## Longitud_Exacta	-0.47	-0.35		0.26		
## Latitud_Inicio	39.32	39.66		0.64		
## Longitud_Inicio	-0.47	-0.34		0.26		
## Latitud_Final	39.32	39.69		0.65		
## Longitud_Final	-0.47	-0.35		0.26		
## Flujo_Vehiculos	142.66	180.00		232.95		
## Valor_Punto_Quilometrico	18883.69	26410.00		21939.30		

Como era de esperar, las variables *Flujo_Vehiculos* y *Valor_Punto_Quilometrico* no toman valores negativos. Las variables que miden longitud y latitud obtienen estadísticos casi idénticos, aunque, si nos fijamos en el rango, vemos que tanto en la longitud como en la latitud (y sobre todo en esta última) de las coordenadas que marcan el final del tramo se observa una mayor variación. Esto nos indica que es probable que haya algún problema con los datos de las coordenadas del tramo final, que veremos más adelante. Por último, cabe recalcar que la media y la mediana de *Flujo_Vehiculos* distan mucho.


Pasemos ahora a representar gráficamente aquellas variables en cuyo caso sea posible. Empezando con las numéricas, nos fijaremos primeramente en *Flujo_Vehiculos*:




En la gráfica podemos observar que lo más común es que el flujo, oscile entre 0 y 250, aunque también hay registros de observaciones en los que el valor del flujo está cerca de 1000. Claramente esta variable no presenta una distribución gaussiana como podría haberse esperado, sino un exponencial.



Si además tenemos en cuenta el tipo de vía, observamos que el flujo de vehículos pesados alcanza mayor número de veces valores más altos en carreteras convencionales y desdobladas. Esto significa que el tránsito de vehículos es mayor en estos tipos de vías.




Por último, podríamos preguntarnos si por alguna peculiar razón el flujo sea diferente dependiendo del sentido circulación. Sin embargo, los datos parecen desmentir esta teoría dada la gran similitud presente entre los histogramas del flujo en sentido ascendente y descendente.




Al igual que Flujo_Vehiculos, Valor_Punto_Quilometrico parece seguir una distribución exponencial, y en su gráfico de caja respecto al tipo de vía podemos apreciar una mayor dispersión en las carreteras desdobladas. También se aprecia claramente como la gran cantidad de outliers presentes en carreteras desdobladas y convencionales influyen en la discrepancia entre media y mediana.

Pasemos ahora a las variables cualitativas. Representaremos primero Tipo_Via y Metodo_Captacion.




Fijémonos en que, si representamos el método de captación desglosándolo según el tipo de carretera podemos sacar dos conclusiones: el método dominante es espiras y las gomas solo se usan en carreteras convencionales.




Por otro lado, en el gráfico de barras se observa claramente que hay más observaciones en las carreteras convencionales que en las autovías o en las carreteras desdobladas. Respecto al resto de variables cualitativas, `Codigo_CV`, `Num_Tramo`, `Sentido`, `Tipo_Vehiculo`, `Ubicacion`, `Tipo_Ubicacion` y `Tipo_valor_Punto_Quilometrico`, no las representaremos por diversos motivos. El primero y más importante es que, debido a la envergadura y cualidades que debe tener este trabajo no podemos pretender hacer una exploración exhaustiva de todas ellas. Luego también hay motivos fundados en la naturaleza de las variables: `Codigo_CV` y `Num_Tramo` toman demasiados valores distintos, por lo que nos es imposible poder representarlos en una gráfica, y no tendría sentido representar `Sentido`, `Tipo_Vehiculo`, `Tipo_Ubicacion` y `Tipo_valor_Punto_Quilometrico`. Esto último se debe a que son variables obtenidas al implementar `pivot_longer()`, por lo que las proporciones de sus valores son iguales y, por así decirlo, sintéticas (es decir, no aportan información).

Por último, reparemos en las variables numéricas que todavía no hemos explorado: las coordenadas geodésicas. Mediante el uso de las librerías `sf` y `mapSpain` (que contiene mapas políticos de España en particular) hemos representado las coordenadas exactas en las que se han tomado las mediciones.




En este mapa se puede comprobar a simple vista que las coordenadas están bien, ya que coinciden con el trazado de las carreteras de la Comunidad Valenciana, y que, como habíamos visto antes con el gráfico de barras, la cantidad de observaciones en carreteras convencionales es considerablemente mayor a la de los otros tipos de vía.

Representamos igualmente las coordenadas de los puntos iniciales y finales de los tramos. Observamos un único punto fuera del territorio a estudiar, en las coordenadas de los puntos finales, que se debe a un error en la recopilación de datos.



5. Análisis bivalente

En este apartado, estudiaremos la linealidad, monotonía y dependencia de las variables de nuestro conjunto de datos. En primer lugar, comenzaremos con las variables numéricas, calculando las matrices de correlación de Pearson y Spearman para determinar si existe una relación lineal y una monotonía entre estas variables. Para ello, representamos los coeficientes de Pearson y Spearman para cada par de variables. Veámoslo:



En la matriz de Pearson (izquierda) se observa una alta correlación positiva entre las variables de latitud y longitud en sus diferentes versiones. Lo que indica que dichas variables están estrechamente relacionadas linealmente, lo cual tiene sentido por su naturaleza geográfica. Por otro lado, la variable Valor_Punto_Quilometrico presenta correlaciones positivas y negativas (bajas) con las coordenadas geográficas. Esto es debido a que esta variable es relativa a cada carretera o tramo. Sin embargo, la variable Flujo_Vehiculos no muestra una correlación lineal significativa con el resto de las variables, lo que indica que el flujo de vehículos no depende directamente de forma lineal con la posición geográfica de los puntos de medición.

La matriz de Spearman (derecha) mantiene un patrón de correlaciones similar al obtenido con Pearson, aunque con ligeras variaciones en la magnitud de los coeficientes. Esto sugiere que las relaciones entre las coordenadas mantienen su monotonía, aunque no

de forma estrictamente ascendente. Cabe destacar la correlación negativa entre Valor_Punto_Quilómetros y las coordenadas se conserva, confirmando la tendencia inversa entre ambas variables. De igual forma, Flujo_Vehículos sigue mostrando baja relación con las demás variables, confirmando su independencia respecto a la localización geográfica.

Ahora estudiaremos la dependencia o independencia entre algunas variables categóricas: Tipo_Via-Metodologia_Captacion, Tipo_Via-Tipo_Vehiculo y Sentido-Tipo_Vehiculo. Para ello, calculamos el coeficiente V de Cramer (que está acotado entre 0 y 1). Obtenemos, respectivamente, 0.076, 0 y 0.

Indicándonos que hay una mínima dependencia entre las variables Tipo_Via-Metodologia_Captacion, Tipo_Via-Tipo_Vehiculo y Sentido-Tipo_Vehiculo. Sin embargo, obtenemos un valor del coeficiente para los pares de variables Tipo_Via-Tipo_Vehiculo y Sentido-Tipo_Vehiculo de 0; por tanto, ambos son totalmente independientes. Podríamos pensar que existe alguna dependencia entre el tipo de vehículo y el tipo de vía por la cual se circula (autovía, convencional o desdoblada), pero observamos que no. En cambio, ya esperábamos que el sentido de circulación (ascendente o descendente) y el tipo de vehículo fueran completamente independientes ya que los vehículos pueden circular indistintamente en un sentido o en otro.

6. Outliers

En este último apartado determinaremos los outliers (datos atípicos) de algunas variables numéricas. Haremos el análisis con la variable Flujo_Vehículos y, también, estudiaremos los outliers de esta variable pero considerando solo los vehículos pesados. Así podremos interpretar de una forma más sencilla los resultados.

Para detectar los outliers aplicaremos la regla de Hampel ya que utiliza estimadores robustos y, además, no presupone que los datos siguen una distribución gaussiana. Podremos observar los picos extremos de flujo de vehículos tanto en el flujo total de vehículos como en el de vehículos pesados.


Respecto a Flujo_Vehículos aparecen un total de 118878 outliers. Esta cantidad elevada (representa el 32.5% del total de registros) puede deberse a que tenemos un conjunto de datos muy segado como podemos ver en las gráficas mostradas en la sección 4. Para interpretar este resultado podemos ver si los outliers presentan alguna relación con alguna otra variable, como por ejemplo, el día de la semana (lunes, martes, etc.) o el tipo de vía.

Para ver si hay relación con el día de la semana podemos ver la proporción de outliers (frecuencia relativa) con respecto al total de outliers según el día:




En este caso, vemos que de lunes a sábado hay una mayor proporción con respecto a los domingos (aunque la distribución es prácticamente uniforme). Esto puede deberse a que, de lunes a sábado, hay desplazamientos diarios de trabajadores o transportes de mercancías, repartos, etc., que no se observan en domingo, y por ello, estos picos más extremos de flujo de vehículos son más probables encontrarlos en estos días.

Ahora, si observamos la proporción de outliers según el tipo de vía, podemos detectar que hay una cantidad superior de outliers en convencional que en autovía y desdoblada. Puede ser debido a que en carretera convencional hay menos carriles, el límite de velocidad máxima es inferior y, por tanto, tiene una menor capacidad de tráfico. Así que, aunque este tipo de vía tiende a tener un flujo de vehículos más uniforme que los otros tipos de vía (en general), cuando aparece algún pico de flujo de vehículos puede ser considerado como outlier.




Por otro lado, tenemos la variable Tipo_Vehiculo que almacena si el vehículo es pesado o no. Haciendo uso de la misma junto con Flujo_Vehiculos, podemos representar la frecuencia relativa de outliers de vehículos pesados por día de la semana, al igual que hemos hecho antes. Veámoslo:



Podemos ver que obtenemos un resultado parecido determinando la proporción de outliers según el día de la semana. Aunque observamos que en sábado y domingo la proporción es bastante menor con respecto al resto de días, ya que en estos días los vehículos pesados no suelen circular ya que no es día laboral.

De esta forma, podríamos mirar que ocurre con los resultados con respecto al tipo de vía. Vemos que los outliers se concentran cuando la carretera es convencional. Aunque los vehículos pesados suelen circular más por autovía, podemos entender que los picos de flujo se encuentren en convencional por una concentración de vehículos puntual (como ocurría cuando considerábamos todos los vehículos).



Data Availability Statement: Los datos usados en este estudio son públicos disponibles en [<https://dadesobertes.gva.es/dataset/tra-int-veh-2025>]

Disclaimer/Publisher's Note: The statements, opinions and data contained in all publications are solely those of the individual author(s) and contributor(s) and not of MDPI and/or the editor(s). MDPI and/or the editor(s) disclaim responsibility for any injury to people or property resulting from any ideas, methods, instructions or products referred to in the content.