

Proyecto Análisis Exploratorio de Datos

María de los Ángeles Díaz Castro, Irene Barba La Orden, Ana Blasco Vega

* Correspondence:

Simple Summary: Preparación y análisis exploratorio del tráfico diario de carreteras en Valencia 2025, obtenido de la página oficial de la Generalitat Valenciana.

Abstract: Este proyecto tiene como objetivo analizar el tráfico en Valencia durante 2025, utilizando datos del dataset público proporcionado por la Generalitat Valenciana. Se consideran 18 variables, de las que se incluyen el número de vehículos que transitan por cada tramo, el método de captación o las coordenadas iniciales y finales de cada registro, entre otras. En total, se han recopilado 15.235 observaciones asociadas a distintos momentos en los que se registró tráfico. Los datos se reestructuraron para facilitar un análisis exploratorio previo, identificando patrones de circulación y posibles anomalías, tratando de ofrecer información valiosa para mejorar la gestión del tráfico y la planificación de las carreteras en Valencia.

1. Introducción.

El tráfico de vehículos va más allá de los números, muestra cómo Valencia se mueve, organiza y enfrenta cada día sus desafíos de desplazamiento. Este proyecto se centra en analizar la intensidad del tráfico en las carreteras de la Comunidad Valenciana durante 2025, a partir de datos públicos proporcionados por la Generalitat Valenciana. A través de un análisis exploratorio de 15.235 observaciones, se busca descubrir patrones de circulación, identificar posibles anomalías y generar información que sea útil para la gestión del transporte. Las visualizaciones y estadísticas que se presentan a lo largo del documento permiten observar de manera clara cómo se mueve Valencia por sus carreteras, ofreciendo una visión tanto cuantitativa como práctica del tráfico en 2025.

2. Importación de los datos.

Para importar los datos, primero se descarga el fichero y se verifica que los datos estén en el directorio adecuado. De esta forma, haciendo uso de la función de importación en R, obtenemos el dataset. Es importante especificar el encoding, ya que, de lo contrario, algunos caracteres pueden no reconocerse correctamente.

```
filename <- './data/intensidad_vehiculos_en_carretera_2025.csv'
vehiculos <- read.csv(filename, sep=";", encoding = "UTF-8")
```

Las 18 variables del dataset son las siguientes:

1. TRAM: Código del tramo al que se le asocia el tráfico.

Primer y segundo dígito: código CV- de la carretera; tres últimos dígitos: número de tramo.

2. DIA: Fecha de los datos.

3. INTA: Total de vehículos que transitan en el sentido ascendente de la kilometración de la carretera.

Citation: . Proyecto Análisis Exploratorio de Datos. *Journal Not Specified* 2024, 1, 0. <https://doi.org/>

Received:

Revised:

Accepted:

Published:

Copyright: © 2025 by the authors. Submitted to *Journal Not Specified* for possible open access publication under the terms and conditions of the Creative Commons Attribution (CC BY) license (<https://creativecommons.org/licenses/by/4.0/>).

4.

INTAP: Total de vehículos pesados que transitan en el sentido ascendente de la kilometración de la carretera.

33
5.

INTD: Total de vehículos que transitan en el sentido descendente de la kilometración de la carretera.

35
6.

INTDP: Total de vehículos pesados que transitan en el sentido descendente de la kilometración de la carretera.

37
7.

INTT: Total de vehículos que pasan por el tramo analizado (este dato será la suma de los dos sentidos anteriores).

39
8.

INTTP: Total de vehículos pesados que pasan por el tramo analizado (este dato será la suma de los dos sentidos anteriores).

41
9.

TIPUSV: Tipo de vía (Autovía, Convencional o Desdoblada).

43
10.

TIPUSE: Procedimiento de captura de tráfico (Espiras, Gomas Neumáticas, Cámaras o Radar).

44
11.

PKE: Posición exacta, en metros, donde se ha captado el tráfico, tomando como referencia la placa de kilometraje anterior en sentido ascendente.

46
12.

PKECOOR: Coordenadas geodésicas en latitud y longitud del punto donde se mide el tráfico.

48
13.

PKINI: Posición inicial del tramo al que se asocia el tráfico, en metros, tomando como referencia la placa kilométrica anterior en sentido ascendente (tráfico invariante en todo el tramo).

50
14.

REFINI: Ubicación del inicio del tramo al que se asocia el tráfico.

53
15.

PKINICOOR: Coordenadas geodésicas en latitud y longitud del punto inicial del tramo al que se asocia el tráfico (tráfico invariante en todo el tramo).

54
16.

PKFI: Posición final del tramo al que se asocia el tráfico, en metros,tomando como referencia la placa kilométrica anterior en sentido ascendente (tráfico invariante en todo el tramo).

56
17.

REFFI: Ubicación del final del tramo al que se asocia el tráfico.

59
18.

PKFICOOR: Coordenadas geodésicas en latitud y longitud del punto final del tramo al que se asocia el tráfico (tráfico invariante en todo el tramo).

60

Es importante revisar el tipo de cada variable para comprender mejor la estructura del dataset, para ello se utilizan las funciones `sapply` y `class`:

```
sapply(vehiculos, class)

##      TRAM      DIA      INTA      INTAP      INTD      INTDP      64
## "integer" "character" "numeric" "numeric" "numeric" "numeric"      65
##      INTT      INTTP      TIPUSV      TIPUSE      PKE      PKECOOR      66
## "numeric" "numeric" "character" "character" "integer" "character"      67
##      PKINI      REFINI      PKINICOOR      PKFI      REFFI      PKFICOOR      68
## "integer" "character" "character" "integer" "character" "character"      69
```

Se puede observar que *DIA* es de tipo `character`, por lo que es necesario convertirla a formato de fecha.

```
vehiculos$DIA <- as.Date(vehiculos$DIA, format = '%d/%m/%Y')
class(vehiculos$DIA)
```

```
## [1] "Date"
```

3. Conversión de los datos a estructura Tidy.

La estructura tidy se caracteriza por tener cada variable en una columna, cada observación en una fila y nombres de columnas que sean representativos. Veamos que ocurre en nuestro dataset.

La columna *TRAM* contiene información del código CV- de la carretera (dos primeros dígitos) y del número de tramo (tres últimos dígitos). Por tanto, primero verificaremos que todos los valores de esta columna tengan cinco dígitos. Si es así, procederemos a dividirla en dos columnas separadas, que se llamarán *Código_{CV}* y *Num_{tramo}*.

```
library(tidyr)
```

```
## Warning: package 'tidyr' was built under R version 4.4.2
```

```
library(dplyr)
```

```
## Warning: package 'dplyr' was built under R version 4.4.3
```

```
##
```

```
## Adjuntando el paquete: 'dplyr'
```

```
## The following objects are masked from 'package:stats':
```

```
##
```

```
## filter, lag
```

```
## The following objects are masked from 'package:base':
```

```
##
```

```
## intersect, setdiff, setequal, union
```

```
all(length(vehiculos$TRAM == 5))
```

```
## [1] TRUE
```

```
vehiculos_tidy <- vehiculos %>%
  separate(col = TRAM, into = c('Código_CV', 'Num_tramo'), sep = 2)
```

Las variables *INTA*, *INTAP*, *INTD*, *INTDP*, *INTT* y *INTTP* contienen información sobre el tipo de vehículo, si es pesado o no, y el sentido del tráfico, ascendente o descendente. Con el fin de estructurar mejor estos datos, aplicamos `pivot_longer()`, generando dos nuevas variables, *Sentido* y *TipoVehículo*.

En la columna *TipoVehículo*, los valores en blanco se rellenan con 'T', que representa cualquier vehículo, mientras que 'P' indica vehículos pesados.

Por otro lado, las columnas *INTT* y *INTTP* representan la intensidad total del tráfico, es decir, la suma de los vehículos que circulan en ambos sentidos (ascendente y descendente), diferenciando si son pesados o no. Dado que esta información puede obtenerse a partir de las demás variables, eliminaremos estas columnas y, en caso de ser necesario, podremos recalcular sus valores sumando las correspondientes columnas de sentido.

```
vehiculos_tidy <- vehiculos_tidy %>%
  pivot_longer(col = starts_with('INT'),
    names_to = c('Sentido', 'Tipo_Vehiculo'),
    names_pattern = '^INT([ADT]){1}(P?)$', values_to = 'Intensidad') %>%
  mutate(Tipo_Vehiculo = ifelse(Tipo_Vehiculo == 'P', 'P', 'T')) %>%
  filter(Sentido != 'T')
```

Del mismo modo, las columnas *PKECOOR*, *PKINICOOR* y *PKFICOOR* contienen las coordenadas geográficas, diferenciando entre la posición inicial, final y exacta. Para reorganizar esta información, aplicamos `pivot_longer()`, que genera dos nuevas columnas: *Coordenadas*, donde se indica el tipo de coordenada (inicial, final o exacta), y *Valor_coordenada*, que almacena su valor correspondiente.

Además, observamos que cada coordenada incluye la latitud y la longitud separadas por un punto y coma. Por ello, utilizamos la función `separate()` para dividir *Valor_coordenada* en dos columnas adicionales: *Latitud* y *Longitud*.

```
vehiculos_tidy <- vehiculos_tidy %>%
  pivot_longer(col = ends_with('COOR'), names_to = 'Coordenadas',
    names_pattern = '^PK(E|INI|FI)COOR$',
    values_to = 'Valor_coordenada') %>%
  separate(col = Valor_coordenada, into = c('Latitud', 'Longitud'), sep=';') %>%
  pivot_longer(col = c(Latitud, Longitud), names_to = 'Tipo_Coordenada',
    values_to = 'Valor_Coordenada')
```

En cuanto a las *REFINI* y *REFFI* recogen las ubicaciones inicial y final del tramo donde se ha detectado el tráfico. Para reorganizar esta información, aplicamos `pivot_longer()`, generando dos nuevas columnas: *Tipo_Ubicación*, que especifica si se trata de la ubicación inicial o final, y *Ubicación*, que que almacena el nombre de la vía o localización.

```
vehiculos_tidy <- vehiculos_tidy %>%
  pivot_longer(col = starts_with('REF'), names_pattern = '^REF(INI|FI)',
    names_to = 'Tipo_Ubicación', values_to = 'Ubicación')
```

Por último, las variables *PKINI*, *PKFI* y *PKE* indican la posición inicial, final y exacta donde se registró el tráfico, tomando como referencia la placa kilométrica anterior en sentido ascendente, suponiendo que el tráfico es invariante en todo el tramo.

Mediante la función `pivot_longer()`, se crean dos nuevas columnas: *Tipo_posición_punto_Quilométrico*, que especifica si la posición corresponde al punto inicial o final, y *Valor_punto_Quilométrico*, que contiene el valor asociado a dicha posición.

```
vehiculos_tidy <- vehiculos_tidy %>%
  pivot_longer(col = matches('^PK(INI|FI|E)'), names_pattern = '^PK(INI|FI|E)',
    names_to = 'Tipo_Posición_Punto_Quilometrico',
    values_to = 'Valor_Punto_Quilometrico')
```

La columna *Valor_coordenada* contiene los valores de latitud y longitud, donde se utilizan comas como separador decimal. Por este motivo, R detecta la columna como tipo `character`, cuando en realidad debería ser numérica. Para solucionarlo, usamos la función `sub()` para reemplazar las comas por puntos, lo que nos permite convertir correctamente los valores a tipo numérico. Veámoslo:

```
str(vehiculos_tidy$Valor_Coordenada)
```

```
## chr [1:2193840] "39,88828171" "39,88828171" "39,88828171" "39,88828171" . . 426
```

```
vehiculos_tidy$Valor_Coordenada <- sub(',', '.', vehiculos_tidy$Valor_Coordenada)
vehiculos_tidy$Valor_Coordenada <-as.numeric(vehiculos_tidy$Valor_Coordenada)
str(vehiculos_tidy$Valor_Coordenada)
```

```
## num [1:2193840] 39.9 39.9 39.9 39.9 39.9 ...
```

Solo falta asegurarnos de que los nombres de las columnas sean representativos, para ello utilizaremos la función rename(); una vez hecho esto, el dataset estará completamente en formato tidy.

```
vehiculos_tidy <- vehiculos_tidy %>%
  dplyr::rename(Fecha = DIA, Tipo_Via = TIPUSV, Metodologia_Captacion= TIPUSE)
```

A continuación, se muestra un fragmento de las primeras filas del dataset, usando la función head():

```
head(vehiculos_tidy)

## # A tibble: 6 x 15
##   Código_CV Num_tramo Fecha      Tipo_Via Metodologia_Captacion Sentido
##   <chr>      <chr>   <date>    <chr>    <chr>                <chr>
## 1 10         007     2025-03-07 Aut.      Espiras              A
## 2 10         007     2025-03-07 Aut.      Espiras              A
## 3 10         007     2025-03-07 Aut.      Espiras              A
## 4 10         007     2025-03-07 Aut.      Espiras              A
## 5 10         007     2025-03-07 Aut.      Espiras              A
## 6 10         007     2025-03-07 Aut.      Espiras              A
## # i 9 more variables: Tipo_Vehiculo <chr>, Intensidad <dbl>, Coordenadas <chr>,
## #   Tipo_Coordenada <chr>, Valor_Coordenada <dbl>, Tipo_Ubicación <chr>,
## #   Ubicación <chr>, Tipo_Posición_Punto_Quilometrico <chr>,
## #   Valor_Punto_Quilometrico <int>
```

Supplementary Materials: The following supporting information can be downloaded at: <https://www.mdpi.com/article/10.3390/1010000/s1>, Figure S1: title; Table S1: title; Video S1: title.

Data Availability Statement: Los datos usados en este estudio son públicos disponibles en [https://dadesobertes.gva.es/dataset/20b91b5a-c26d-4624-bcf5-b76a74b3ec88/resource/abe57190-d53d-4d41-9266-d7c2254621ae/download/intensidad_vehiculos_en_carretera_2025.csv]

Abbreviations

The following abbreviations are used in this manuscript:

MDPI	Multidisciplinary Digital Publishing Institute	
DOAJ	Directory of open access journals	
TLA	Three letter acronym	
LD	linear dichroism	

Appendix A

Appendix A.1

The appendix is an optional section that can contain details and data supplemental to the main text—for example, explanations of experimental details that would disrupt the flow of the main text but nonetheless remain crucial to understanding and reproducing the research shown; figures of replicates for experiments of which representative data are shown in the main text can be added here if brief, or as Supplementary Data. Mathematical proofs of results not central to the paper can be added as an appendix.

Table A1. This is a table caption.

Title 1	Title 2	Title 3
Entry 1	Data	Data
Entry 2	Data	Data

Appendix B

All appendix sections must be cited in the main text. In the appendices, Figures, Tables, etc. should be labeled, starting with “A”—e.g., Figure A1, Figure A2, etc.

Disclaimer/Publisher’s Note: The statements, opinions and data contained in all publications are solely those of the individual author(s) and contributor(s) and not of MDPI and/or the editor(s). MDPI and/or the editor(s) disclaim responsibility for any injury to people or property resulting from any ideas, methods, instructions or products referred to in the content.