

Proyecto Análisis Exploratorio de Datos

María de los Ángeles Díaz Castro, Irene Barba La Orden, Ana Blasco Vega

* Correspondence:

1. Introducción.

El tráfico de vehículos va más allá de los números, muestra cómo Valencia se mueve, organiza y enfrenta cada día sus desafíos de desplazamiento. Este proyecto se centra en analizar la intensidad del tráfico en las carreteras de la Comunidad Valenciana durante el primer semestre de 2025, a partir de datos públicos proporcionados por la Generalidad Valenciana. A través de un análisis exploratorio de 15.235 observaciones, se busca detectar las posibles anomalías en el tráfico y explorar el comportamiento de la movilidad en Valencia.

2. Importación de los datos.

Para importar los datos, primero se descarga el fichero y se verifica que los datos estén en el directorio adecuado. Es importante especificar el encoding (en nuestro caso es UTF-8), ya que, de lo contrario, algunos caracteres pueden no reconocerse correctamente. De esta forma, haciendo uso de la función de importación en R con los parámetros adecuados, obtenemos el dataset.

Las variables de nuestro dataset son las siguientes:

- TRAM** (*numérico*): Código del tramo al que se le asocia el tráfico.
Primer y segundo dígito: código CV- de la carretera; tres últimos dígitos: número de tramo.
- DIA** (*carácter*): Fecha de los datos.
- INTA** (*numérico*): Total de vehículos que transitan en el sentido ascendente de la kilometración de la carretera.
- INTAP** (*numérico*): Total de vehículos pesados que transitan en el sentido ascendente de la kilometración de la carretera.
- INTD** (*numérico*): Total de vehículos que transitan en el sentido descendente de la kilometración de la carretera.
- INTDP** (*numérico*): Total de vehículos pesados que transitan en el sentido descendente de la kilometración de la carretera.
- INTT** (*numérico*): Total de vehículos que pasan por el tramo analizado (este dato será la suma de los dos sentidos anteriores).
- INTTP** (*numérico*): Total de vehículos pesados que pasan por el tramo analizado (este dato será la suma de los dos sentidos anteriores).
- TIPUSV** (*carácter*): Tipo de vía (Autovía, Convencional o Desdoblada).
- TIPUSE** (*carácter*): Procedimiento de captura de tráfico (Espiras, Gomas Neumáticas, Cámaras o Radar).

Citation: . Proyecto Análisis Exploratorio de Datos. *Journal Not Specified* **2024**, *1*, 0. <https://doi.org/>

Received:

Revised:

Accepted:

Published:

Copyright: © 2025 by the authors. Submitted to *Journal Not Specified* for possible open access publication under the terms and conditions of the Creative Commons Attribution (CC BY) license (<https://creativecommons.org/licenses/by/4.0/>).

11. **PKE** (*numérico*): Posición exacta, en metros, donde se ha captado el tráfico, tomando como referencia la placa de kilometraje anterior en sentido ascendente.
12. **PKECOOR** (*carácter*): Coordenadas geodésicas en latitud y longitud del punto donde se mide el tráfico.
13. **PKINI** (*numérico*): Posición inicial del tramo al que se asocia el tráfico, en metros, tomando como referencia la placa kilométrica anterior en sentido ascendente (tráfico invariante en todo el tramo).
14. **REFINI** (*carácter*): Ubicación del inicio del tramo al que se asocia el tráfico.
15. **PKINICOOR** (*carácter*): Coordenadas geodésicas en latitud y longitud del punto inicial del tramo al que se asocia el tráfico (tráfico invariante en todo el tramo).
16. **PKFI** (*numérico*): Posición final del tramo al que se asocia el tráfico, en metros, tomando como referencia la placa kilométrica anterior en sentido ascendente (tráfico invariante en todo el tramo).
17. **REFFI** (*carácter*): Ubicación del final del tramo al que se asocia el tráfico.
18. **PKFICOOR** (*carácter*): Coordenadas geodésicas en latitud y longitud del punto final del tramo al que se asocia el tráfico (tráfico invariante en todo el tramo).

Si le echamos un vistazo a las variables, podemos ver que la variable *DIA* es de tipo *character*, por lo que es necesario convertirla a formato de fecha. Para ello, usamos la función `as.Date()`. Por otro lado, es importante preguntarse con cuántos valores faltantes estamos trabajando, para ello usamos `is.na()` y sumamos los valores faltantes, obteniendo:

```
## [1] 0
```

Como no tenemos valores faltantes, no será necesario llevar a cabo ningún proceso de imputación o similar.

3. Conversión de los datos a estructura Tidy.

La estructura tidy se caracteriza por tener cada variable en una columna, cada observación en una fila y nombres de columnas que sean representativos. Para obtener un conjunto tidy, vamos a realizar diversas transformaciones en nuestros datos para facilitar su análisis.

Comenzamos reorganizando las variables relacionadas con la intensidad del tráfico (*INTA*, *INTAP*, *INTD*, *INTDP*, *INTT* y *INTTP*). Estas columnas almacenan información sobre el sentido del tráfico (ascendente, descendente o total) y el tipo de vehículo (pesado o total), por lo que están estrechamente relacionadas entre sí.

Para convertir el conjunto de datos en tidy, optamos por transformar el formato ancho en uno largo, de modo que cada fila represente una combinación única de tramo, sentido y tipo de vehículo. Para ello aplicamos la función `pivot_longer()`, que nos permite condensar varias columnas en dos nuevas variables: *Sentido*, que indica la dirección del tráfico, y *Tipo_Vehiculo*, que diferencia entre vehículos pesados (P) y el total (T).

De forma análoga, se aplicaron transformaciones similares a otras variables, como *TRAM*, las ubicaciones (*REFINI*, *REFFI*) y los puntos kilométricos (*PKINI*, *PKFI*, *PKE*). En el caso de las variables de coordenadas (*PKECOOR*, *PKINICOOR*, *PKFICOOR*), que distinguen entre la posición inicial, final y exacta, como cada coordenada incluye la latitud y la longitud separadas por un punto y coma, usamos la función `separate()` para dividir cada columna en longitud y latitud. El separador decimal del conjunto eran las comas, por lo que R detectaba las columnas como tipo carácter. Lo solucionamos usando la función `sub()` para reemplazar las comas por puntos, lo que nos permite convertir correctamente los valores a tipo numérico. Después de convertirlas a tipo numérico, acabamos con las variables

Latitud_Inicio, Longitud_Inicio, Latitud_Final, Longitud_Final, Latitud_Exacta y Longitud_Exacta.

De esta forma, como Valor_Coordenada utiliza comas como separador decimal, R detecta la columna como tipo character, cuando en realidad debería ser numérica. Para solucionarlo, usamos la función `sub()` para reemplazar las comas por puntos, lo que nos permite convertir correctamente los valores a tipo numérico.

Solo falta asegurarnos de que los nombres de las columnas sean representativos; para ello, utilizamos la función `rename()` y reemplazamos algunos valores abreviados por descripciones completas mediante la función `ifelse()`. Por ejemplo, en las variables relacionadas con ubicación, los códigos *INI*, *E* y *FI* se sustituyeron por *Inicial*, *Exacta* y *Final*; en *Sentido*, los valores *A* y *D* pasaron a *Ascendente* y *Descendente*; y en *Tipo_Vehiculo*, *T* y *P* se cambiaron por *Todos* y *Pesados*.

Comenzamos reorganizando las variables relacionadas con la intensidad del tráfico (*INTA*, *INTAP*, *INTD*, *INTDP*, *INTT* y *INTTP*). Estas columnas almacenan información sobre el sentido del tráfico (ascendente, descendente o total) y el tipo de vehículo (pesado o total), por lo que están estrechamente relacionadas entre sí.

Para convertir el conjunto de datos en tidy, optamos por transformar el formato ancho en uno largo, de modo que cada fila represente una combinación única de tramo, sentido y tipo de vehículo. Para ello aplicamos la función `pivot_longer()`, que nos permite condensar varias columnas en dos nuevas variables: *Sentido*, que indica la dirección del tráfico, y *Tipo_Vehiculo*, que diferencia entre vehículos pesados (P) y el total (T).

De forma análoga, se aplicaron transformaciones similares a otras variables, como *TRAM*, las ubicaciones (*REFINI*, *REFFI*) y los puntos kilométricos (*PKINI*, *PKFI*, *PKE*). En el caso de las variables de coordenadas (*PKECOORD*, *PKINICCOORD*, *PKFICCOORD*), que distinguen entre la posición inicial, final y exacta, como cada coordenada incluye la latitud y la longitud separadas por un punto y coma, usamos la función `separate()` para dividir cada columna en longitud y latitud. El separador decimal del conjunto eran las comas, por lo que R detectaba las columnas como tipo carácter. Lo solucionamos usando la función `sub()` para reemplazar las comas por puntos, lo que nos permite convertir correctamente los valores a tipo numérico. Después de convertirlas a tipo numérico, acabamos con las variables *Latitud_Inicio*, *Longitud_Inicio*, *Latitud_Final*, *Longitud_Final*, *Latitud_Exacta* y *Longitud_Exacta*.

Solo falta asegurarnos de que los nombres de las columnas sean representativos; para ello, utilizamos la función `rename()` y reemplazamos algunos valores abreviados por descripciones completas mediante la función `ifelse()`. Por ejemplo, en las variables relacionadas con ubicación, los códigos *INI*, *E* y *FI* se sustituyeron por *Inicial*, *Exacta* y *Final*; en *Sentido*, los valores *A* y *D* pasaron a *Ascendente* y *Descendente*; y en *Tipo_Vehiculo*, *T* y *P* se cambiaron por *Todos* y *Pesados*.

A continuación, se muestra un fragmento de las primeras filas del dataset, usando la función `head()`:

```
## # A tibble: 6 x 18
##   Codigo_CV Num_tramo Fecha      Tipo_Via Metodologia_Captacion Latitud_Exacta
##   <chr>      <chr>    <date>    <chr>    <chr>                <dbl>
## 1 10         007      2025-03-07 Autovia   Espiras              39.9
## 2 10         007      2025-03-07 Autovia   Espiras              39.9
## 3 10         007      2025-03-07 Autovia   Espiras              39.9
## 4 10         007      2025-03-07 Autovia   Espiras              39.9
## 5 10         007      2025-03-07 Autovia   Espiras              39.9
## 6 10         007      2025-03-07 Autovia   Espiras              39.9
## # i 12 more variables: Longitud_Exacta <dbl>, Latitud_Inicio <dbl>,
## #   Longitud_Inicio <dbl>, Latitud_Final <dbl>, Longitud_Final <dbl>,
## #   Sentido <chr>, Tipo_Vehiculo <chr>, Flujo_Vehiculos <dbl>,
## #   Tipo_Ubicacion <chr>, Ubicacion <chr>,
## #   Tipo_Posicion_Punto_Kilometrico <chr>, Valor_Punto_Kilometrico <int>
```

4. Análisis univariante y gráficos exploratorios


En esta sección exploraremos los datos mediante un análisis univariante de las variables numéricas y el uso de gráficos. Las variables numéricas de las que disponemos son Flujo_Vehiculos, Valor_Punto_Quilometrico, y las coordenadas geográficas de los puntos en los que se mide el flujo, así como las de los puntos que se han designado como inicio y fin del tramo en el que se asume que el tráfico es invariante.

##	Mínimo	Máximo	Rango	IQR	Q0.25	Mediana
## Latitud_Exacta	37.89	40.71	2.82	0.81	38.87	39.54
## Longitud_Exacta	-1.20	0.43	1.63	0.29	-0.64	-0.50
## Latitud_Inicio	37.89	40.65	2.76	0.81	38.86	39.53
## Longitud_Inicio	-1.21	0.43	1.65	0.28	-0.62	-0.49
## Latitud_Final	37.13	40.73	3.60	0.80	38.89	39.54
## Longitud_Final	-1.25	0.44	1.69	0.29	-0.64	-0.50
## Flujo_Vehiculos	0.00	999.00	999.00	175.84	4.16	16.63
## Valor_Punto_Quilometrico	0.00	95090.00	95090.00	22910.00	3500.00	10200.00
##	Media	Q0.75	Desviación_típica			
## Latitud_Exacta	39.32	39.68		0.65		
## Longitud_Exacta	-0.47	-0.35		0.26		
## Latitud_Inicio	39.32	39.66		0.64		
## Longitud_Inicio	-0.47	-0.34		0.26		
## Latitud_Final	39.32	39.69		0.65		
## Longitud_Final	-0.47	-0.35		0.26		
## Flujo_Vehiculos	142.66	180.00		232.95		
## Valor_Punto_Quilometrico	18883.69	26410.00		21939.30		

#####HABLA DE ALGO MÁS GENERAL, EN PLAN QUE VEAS LOS RESULTADOS QUE TE SALEN UN POCO POR ENCIMA LO DESTACABLE

Si nos fijamos en el rango, vemos que tanto en la longitud como en la latitud (y sobre todo en esta última) de las coordenadas que marcan el final del tramo se observa una mayor variación. Esto nos indica que es probable que haya algún problema con los datos de las coordenadas del tramo final, que veremos más adelante.

Pasemos ahora a representar gráficamente aquellas variables en cuyo caso sea posible. Empezando con las numéricas, nos fijaremos primeramente en Flujo_Vehiculos:




««««< HEAD

En la gráfica podemos observar que lo más común es que el flujo, oscile entre 0 y 250, aunque también hay registros de observaciones en los que el valor del flujo está cerca de 1000.

5. Relación entre las variables

En este apartado estudiaremos si existe una relación lineal entre las variables de nuestro conjunto de datos. En primer lugar, comenzaremos con las variables numéricas, calculando las matrices de correlación de Pearson y Spearman con la función cor() para determinar si existe o no una relación entre estas variables y las representaremos. Veámoslo:



En la matriz de Pearson (izquierda) se observa una alta correlación positiva entre las variables de latitud y longitud en sus diferentes versiones. Lo que indica que dichas variables están estrechamente relacionadas de manera lineal, lo cual tiene sentido por su naturaleza geográfica. Por otro lado, la variable Valor_Punto_Quilométrico presenta una correlación negativa moderada a alta con las coordenadas geográficas. Esto puede deberse a que a medida que varía el punto kilométrico, también se produce una variación inversa en la posición (latitud o longitud), lo que indica que los puntos de medición están ordenados espacialmente a lo largo del trazado de la vía. Sin embargo, la variable Flujo_Vehículos no muestra una correlación lineal significativa con el resto de las variables, lo que indica que el flujo de vehículos no depende directamente de la posición geográfica de los puntos de medición.

No obstante, la matriz de Spearman (derecha) mantiene un patrón de correlaciones similar al obtenido con Pearson, aunque con ligeras variaciones en la magnitud de los coeficientes. Esto sugiere que las relaciones entre las coordenadas mantienen su monotonía, aunque no de forma estrictamente lineal. Cabe destacar la correlación negativa entre Valor_Punto_Quilométrico y las coordenadas se conserva, confirmando la tendencia inversa entre ambas variables. De igual forma, Flujo_Vehículos sigue mostrando baja relación con las demás variables, confirmando su independencia respecto a la localización geográfica.

Ahora estudiaremos la dependencia o independencia entre algunas variables categóricas: Tipo_Via-Metodologia_Captacion, Tipo_Via-Tipo_Vehiculo, Sentido-Tipo_Vehiculo. Comenzando con las dos primeras variables, calculamos el coeficiente V de Cramer (que está acotado entre 0 y 1):

```
## [1] 0.07673791
```

Lo que nos indica que hay dependencia pero las variables prácticamente no se influyen entre sí. Veamos que ocurre con las otras variables:

```
## [1] 0
```

```
## [1] 0
```

Obtenemos un valor del coeficiente para los pares de variables Tipo_Via-Tipo_Vehículo y Sentido-Tipo_Vehículo de 0; por tanto, ambos pares son independientes. Podríamos pensar que existe alguna dependencia entre el tipo de vehículo y el tipo de vía por la que se circula (autovía, convencional o desdoblada), pero observamos que no. En cambio, ya esperábamos que el sentido de circulación (ascendente o descendente) y el tipo de vehículo fueran completamente independientes ya que el tipo de vehículo no depende del sentido del trayecto (los vehículos pueden circular indistintamente en un sentido o en otro).

6. Outliers

En este último apartado determinaremos los outliers (datos atípicos) de algunas variables numéricas. Comenzaremos con Intensidad_Total e Intensidad_Total_Pesados (flujo de vehículos total sumando ambos sentidos de circulación para todos los vehículos y para los vehículos pesados, respectivamente), que son “variables” del conjunto no tidy. Utilizaremos este conjunto para interpretar de una forma más sencilla los resultados.


Para detectar los outliers aplicaremos la regla de Hampel ya que utiliza estimadores robustos y, además, no presupone que los datos siguen una distribución gaussiana. Podremos observar los picos extremos de flujo de vehículos tanto en el flujo total de vehículos como en el de vehículos pesados.

Respecto a la variable Intensidad_Total aparecen un total de 2656 outliers. Esta cantidad elevada (aunque representa el 17.4% del total de registros) puede deberse a que tenemos un conjunto de datos muy segado como podemos ver en las Figuras Para interpretar este resultado podemos ver si los outliers presentan alguna relación con alguna otra variable, como por ejemplo, el día de la semana (lunes, martes, etc.) o el tipo de vía.

Para ver si hay algún tipo de relación con el día de la semana podemos ver la proporción de outliers (frecuencia relativa) con respecto al total de outliers según el día:


[1] 118878

[1] "es_ES.UTF-8"




En este caso, vemos que en los días laborales (de lunes a viernes) hay una mayor proporción con respecto a los días correspondientes al fin de semana (sábado y domingo). Esto puede deberse a que, entre semana, hay desplazamientos diarios de trabajadores o transportes de mercancías, repartos... que no se observan en fin de semana, y por ello, estos picos de flujo de vehículos se pueden encontrar en esos días.

Ahora, si observamos la proporción de outliers según el tipo de vía, podemos detectar que hay una cantidad superior de outliers en autovía y carretera desdoblada que en carretera convencional. Puede ser debido a que en carretera convencional hay menos carriles, el límite de velocidad máxima es inferior y, por tanto, tiene una menor capacidad de tráfico. Así que, este tipo de vía tiende a tener un flujo de vehículos más uniforme que en los otros tipos de vía, en general.




Por otro lado, tenemos la variable `Tipo_Vehiculo` que almacena si el vehículo es pesado o no. Haciendo uso de la misma junto con `Flujo_Vehículos`, podemos representar la frecuencia relativa de outliers de vehículos pesados por día de la semana, al igual que del resto de vehículos. Veámoslo:

```
## [1] "es_ES.UTF-8"
```



Podemos ver que obtenemos un resultado parecido determinando la proporción de outliers según el día de la semana. Aunque podemos ver que en domingo la proporción es menor ya que en este día los vehículos pesados no suelen circular ya que no es día laboral.

De esta forma, podríamos mirar que ocurre con los resultados con respecto al tipo de vía, vemos que los outliers se concentran cuando la carretera es convencional. Aunque los vehículos pesados suelen circular más por autovía, podemos entender que los picos de flujo se encuentren en convencional por una concentración de vehículos puntual.



Por último, también podemos verificar si las coordendas (latitud y longitud) son correctas, es decir, si todos los puntos se encuentran dentro de la Comunidad Valenciana mediante un mapa. Observamos un único punto fuera del territorio a estudiar, que puede deberse a un error en la recopilación de datos.

Data Availability Statement: Los datos usados en este estudio son públicos disponibles en [<https://dadesobertes.gva.es/dataset/tra-int-veh-2025>]

Disclaimer/Publisher's Note: The statements, opinions and data contained in all publications are solely those of the individual author(s) and contributor(s) and not of MDPI and/or the editor(s). MDPI and/or the editor(s) disclaim responsibility for any injury to people or property resulting from any ideas, methods, instructions or products referred to in the content.

264
265
266